




Correlación de Variables Aleatorias

Introducción a la Ciencia de Datos – MaIE, Udenar

Correlación

Consideremos dos variables aleatorias X y Y .



Caso 1: a medida que X crece, Y también crece (correlación positiva)

Caso 2: a medida que X crece, Y decrece (correlación negativa)

Caso 3: X y Y no están correlacionadas.

Para medir la **correlación** usamos la **covarianza**

Covarianza

Definición (covarianza): Sean X y Y variables aleatorias. La covarianza de X y Y se define como

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

Cálculo de la **covarianza** con N datos:

$$\text{Cov}(X, Y) = \frac{\sum_{i=1}^N (x_i - \mu_x)(y_i - \mu_y)}{N - 1}$$

- $\text{Cov}(X, Y) > 0 \rightarrow$ correlación positiva entre X y Y .
- $\text{Cov}(X, Y) < 0 \rightarrow$ correlación negativa entre X y Y .
- $\text{Cov}(X, Y) = 0 \rightarrow$ no hay correlación entre X y Y .

no correlación $\neq$ independencia

Correlación $\neq$ Independencia

Considere las variables aleatorias X y $Y = X^2$, donde

$$p_X(a) = \begin{cases} 1/4, & a = 1 \\ 1/2, & a = 0 \\ 1/4, & a = -1 \end{cases}$$

Claramente, X y Y **son dependientes**. X y Y están correlacionadas?

Sol: Para saberlo, calculemos $\text{Cov}(X, Y) = 0 \longrightarrow X$ y Y **no** están correlacionadas!

Coeficiente de Correlación de Pearson

Definición (coeficiente de correlación): Sean X y Y variables aleatorias con desviaciones estándar σ_X y σ_Y , respectivamente. El coeficiente de correlación de X y Y se define como:


$$\rho = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

El coeficiente de correlación y la covarianza tienen el mismo signo, entonces:

- $\rho > 0 \rightarrow$ correlación positiva entre X y Y .
- $\rho < 0 \rightarrow$ correlación negativa entre X y Y .
- $\rho = 0 \rightarrow$ no hay correlación entre X y Y .

Además:

$\rho = 1 \longrightarrow \rho = 0 \longrightarrow \rho = -1$



Covarianza y Coeficiente de Correlación en Python

```
import pandas as pd

# 1. Creamos un dataset de ejemplo
data = {
    'Variable_X': [1, 2, 3, 4, 5, 6, 7],
    'Variable_Y': [2, 3, 5, 4, 6, 8, 9]
}
df = pd.DataFrame(data)

# --- COVARIANZA ---

# Covarianza entre dos columnas específicas
cov_xy = df['Variable_X'].cov(df['Variable_Y'])
print(f"Covarianza entre X e Y: {cov_xy}")

# Matriz de covarianza de todo el dataset
matriz_cov = df.cov()
print("\nMatriz de Covarianza:")
print(matriz_cov)

# --- CORRELACIÓN DE PEARSON ---

# Correlación de Pearson entre dos columnas específicas
corr_xy = df['Variable_X'].corr(df['Variable_Y'], method='pearson')
print(f"\nCorrelación de Pearson entre X e Y: {corr_xy}")

# Matriz de correlación de todo el dataset
matriz_corr = df.corr(method='pearson')
print("\nMatriz de Correlación de Pearson:")
print(matriz_corr)
```

Covarianza entre X e Y: 5.333333333333334

Matriz de Covarianza:

	Variable_X	Variable_Y
Variable_X	4.666667	5.333333
Variable_Y	5.333333	6.571429

Correlación de Pearson entre X e Y: 0.9630868246861539

Matriz de Correlación de Pearson:

	Variable_X	Variable_Y
Variable_X	1.000000	0.963087
Variable_Y	0.963087	1.000000

