






Limpieza de Datos Datos con Python y Pandas

La Regla del 75%: El Trabajo Real del Científico de Datos



El Trabajo Principal


La limpieza de datos no es solo un paso previo; es el núcleo de la ciencia de datos.



La Regla de Oro

"Garbage in, Garbage out." Si entra basura, sale basura. Un modelo avanzado jamás compensará datos de mala calidad.

El Pipeline de Limpieza: 5 Estaciones de Refinamiento



1. Estructura y Redundancia

Eliminar ruido y duplicados.

2. Valores Nulos

Diagnóstico e imputación.

3. Texto y Formato

Estandarización de cadenas.

4. Valores Atípicos

Detección de anomalías (Outliers).

5. Transformación

Reformateo y enriquecimiento.

Estación 1: Estructura y Redundancia

Eliminar Columnas Irrelevantes

No todos los datos son útiles (ej. IDs internos, columnas sin varianza).

```
df.drop(columns=['No_Util', 'Licencia'],  
inplace=True)
```

ID	Valor	No_Util	Licencia
1	5	0	-
2	3	0	-
3	3	-	-
4	4	-	-



ID	Valor
1	5
2	2

Eliminar Registros Duplicados

Evitar sesgos eliminando filas idénticas que distorsionan el modelo.

```
df.drop_duplicates(inplace=True)
```

A	B	C
1	5	1
2	3	2
3	3	2
X	X	X




A	B	C
1	5	1
2	3	2
3	3	2

Estación 2: El Dilema de los Datos Faltantes

Los modelos de Machine Learning no toleran los valores nulos. El primer paso es el diagnóstico numérico; la acción a tomar depende totalmente de la proporción de datos faltantes.

Visual Diagnostic



Code Console

Total de nulos por columna


```
df.isna().sum()
```

Porcentaje exacto de huecos

```
(df.isna().sum() / len(df)) * 100
```




Árbol de Decisión: ¿Eliminar o Imputar?



Estación 3: Estandarización de Cadenas de Texto

Dato Sucio	Operación Pandas	Dato OK
'management', 'Management', 'MANAGEMENT'	<code>df['Job'].str.lower()</code>	'management'
' Potter ', 'Potter '	<code>df['Name'].str.strip()</code>	'Potter'
'Y', 'N'	<code>df['Pay_Cust'].replace ({'Y': 'Yes', 'N': 'No'})</code>	'Yes', 'No'


Disección de Código: Regex y Funciones Lambda



Separación de Valores y Tipos de Datos

Una columna no debe esconder múltiples variables. **expand=True** convierte la separación en nuevas columnas.

```
df['Address'].str.split(',', expand=True)
```



Los números disfrazados de texto rompen los cálculos. Elimina los símbolos y fuerza el tipo con **astype()**.


```
df['Price'].str.replace('$', '').str.replace(',', '').astype(int)
```



Estación 4: Detección de Valores Atípicos


Método IQR (Rango Inter cuartílico)

Robusto ante datos asimétricos. Ideal para distribuciones no normales.




Método 3x Desviación Estándar

Ideal para datos con distribución normal (forma de campana).



Estación 5: Reformateo de Datos (Wide to Long)

A los humanos nos encantan las tablas anchas; las bases de datos y herramientas de BI (como Tableau) exigen tablas largas. Solucíonalo con la función melt.



Unión de DataFrames

El 'Left Join' garantiza que no perdamos ninguna respuesta del usuario, simplemente le adjuntamos el contexto adicional donde encuentre coincidencia.

Tabla Principal
(Respuestas de Usuarios)


Llave (On):
Pregunta_ID

Tabla Secundaria
(Texto de Preguntas)


```
pd.merge(df_respuestas, df_preguntas, how='left', on='Pregunta_ID')
```


El Toque Final: Reindexación y Exportación

Reparar el Índice

Tras eliminar nulos y duplicados, el índice numérico interno queda roto. Esta función lo reinicia de forma limpia el rastro viejo.

```
df.reset_index(drop=True, inplace=True)
```



Exportar Los Datos Limpios

Guarda tu dataset pulido. `index=False` evita que Pandas exporte el número de fila como una columna inútil en Excel.

```
df.to_csv('datos_limpios.csv', index=False)
```

