

Regresión Lineal

Introducción a la Ciencia de Datos – MaIE, Udenar

Regresión Lineal Multivariable (MLR)

- Permite **estimar** un resultado (**variable dependiente**) usando la información de **varios predictores** (**variables dependientes**).
- Es un modelo **interpretable** porque permite determinar:
 - Qué predictor tiene mayor peso en la estimación.
 - Cuánto cambia el resultado por cada unidad que cambia un predictor.

Modelo de la MLR


$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \epsilon$$

y es la variable a estimar

$x_1, \dots, x_n$ son los predictores

$\beta_0, \dots, \beta_n$ son los coeficientes


ϵ es el error de la estimación



Modelo de la MLR (ej. Precio apartamento)

$$\text{precio} = \$50 + \$1.2(\text{metros}) + \$8(\text{habitaciones}) - 1.5(\text{antigüedad}) + \epsilon$$


1 habitación adicional impacta más el precio que 1 metro cuadrado adicional



los años de antigüedad impactan negativamente


Supuestos del Modelo

1. Linealidad: Relación lineal entre predictores y variable objetivo.




Supuestos del Modelo (cont. 1)

2. Homocedasticidad: Varianza de errores constante en todo el rango de los predictores.




Supuestos del Modelo (cont. 2)

3. Normalidad de errores: Los errores se distribuyen normalmente.



Supuestos del Modelo (cont. 3)

4. No Multicolinealidad: La correlación entre predictores debe ser baja (dos predictores no deben explicar lo mismo)



Cálculo de los Coeficientes

Tenemos M datos:

$$\left(y^{(1)}, x_1^{(1)}, x_2^{(1)}, \dots, x_n^{(1)} \right)$$

...


$$\left(y^{(M)}, x_1^{(M)}, x_2^{(M)}, \dots, x_n^{(M)} \right)$$

Aplicamos **mínimos cuadrados**:

$$\min_{\beta_0, \dots, \beta_n} \sum_{i=1}^M \left(y^{(i)} - \hat{y}^{(i)} \right)^2$$

donde $\hat{y}$ es la estimación:

$$\hat{y}^{(i)} = \beta_0 + \beta_1 x_1^{(i)} + \beta_2 x_2^{(i)} + \dots + \beta_n x_n^{(i)}$$



Pruebas de Ajuste

Error cuadrático medio (MSE): Mide qué tan exactas son las estimaciones.

$$MSE = \sum_{i=1}^M \left(y^{(i)} - \hat{y}^{(i)} \right)^2$$

Coeficiente de Determinación R^2 : variabilidad de la estimación que logra explicar el modelo (en porcentaje).

$$R^2 = 1 - \frac{\sum_{i=1}^M \left(y^{(i)} - \hat{y}^{(i)} \right)^2}{\sum_{i=1}^M \left(y^{(i)} - \bar{y} \right)^2}$$